

Project Idea Proposal: AI-Driven Multi-Segment Urban Waste Generation Estimation & Municipal Social Marketing Optimization

1. Project Idea

- **Problem Definition:** Belediyeler ve yerel yönetimler, "Sıfır Atık" hedeflerine ulaşmak için yürüttükleri geri dönüşüm kampanyalarında tüm kente tek tip (kitle) mesajları vermektedir. Ancak kentsel atık üreticileri homojen değildir; KOBİ'lerin ambalaj çıktısı, HoReCa'nın atık yağı, hanelerin evsel atığı ve bireylerin sokaktaki tüketim dinamikleri birbirinden tamamen farklıdır. Bu veri eksikliği ve hedefsiz kamu iletişimi; vatandaş/esnaf katılım oranının %10–15 bandında kalmasına, ayrıştırma kutularının atıl kalmasına ve belediyelerin katı atık depolama sahalarına (*tipping fee*) milyonlarca lira gereksiz bertaraf ücreti ödemesine neden olmaktadır.
- **Project Goal:** KOBİ, HoReCa, Hane ve Birey olmak üzere 4 temel kentsel segmentin atık üretim hacmi ve türünü mikro ölçekte (bina/parsel bazında) tahmin eden; tahmin edilen atık yoğunluklarını mekânsal olarak kümeleyerek belediyelerin hedefli sosyal pazarlama (teşvik, ödül, randevulu toplama, konteyner/otomat konumlandırma) kararlarını optimize eden bir **Makine Öğrenmesi Tabanlı Çoklu Segmentasyon ve Atık Tahmin Sistemi** geliştirmektir.

2. Relevance to Sustainable Development Goals (SDGs)

- **SDG 11: Sürdürülebilir Şehirler ve Topluluklar (Hedef 11.6):** Kentsel atık toplama ve ayrıştırma altyapısını optimize ederek kentsel lojistik kaynaklı karbon salımını, hava kirliliğini ve katı atık depolama sahalarının çevresel baskısını azaltır.
- **SDG 12: Sorumlu Üretim ve Tüketim (Hedef 12.5):** Kaynağında ayrıştırma oranını artırarak geri dönüştürülebilir ambalajların (karton, plastik, cam) ve organik atıkların çöpe gitmesini engeller, döngüsel ekonomiye kazandırılan hammadde miktarını yükseltir.
- **SDG 13: İklim Eylemi:** Organik ve gıda atıklarının vahşi depolama alanlarında çürümesi sonucu oluşan metan gazı salımını kaynağında kompost ve biyogaz yönlendirmesiyle minimize eder.

3. Literature Examples

- **Kontokosta, C. E., & Hong, Y. (2018):** *"Machine Learning Models for Predicting Building-level Waste Generation."*
 - **Özet:** New York City'deki konut ve ticari binaların mekânsal, fiziksel ve kullanım türü verilerini kullanarak Gradient Boosting ve Random Forest algoritmalarıyla bina düzeyinde atık miktarını modellemiştir. Geleneksel kişi başı sabit katsayı yöntemlerine kıyasla $R^2 > 0.85$ doğruluk elde etmiş; bina kullanım türü ve alan büyüklüğünün tahmindeki en kritik değişkenler olduğunu kanıtlamıştır.

- **Abbasi, M., & El Hanandeh, A. (2016):** "Forecasting municipal and commercial solid waste generation using machine learning."

- **Özet:** Destek Vektör Makineleri (SVM) ve Yapay Sinir Ağları (ANN) kullanarak ticari ve kentsel katı atık üretim trendlerini modellemiştir. Sektörel sınıflandırmanın ve dönemsel kentsel hareketliliğin atık çıktısı üzerindeki doğrusal olmayan etkilerini doğrulamıştır.

4. Describe Your Data

- **Veri Kaynakları:**

1. *Ticari & HoReCa Verileri:* NACE faaliyet kodları, ruhsat kapasitesi/masa sayısı, Google Places API popüler saatler ve müşteri yoğunluk indeksi.
2. *Mekânsal & Konut Verileri:* OpenStreetMap kapalı alan ($\$m^2$), TÜİK ADNKS mahalle nüfus/hane halkı büyüklüğü ve SEGE sosyo-ekonomik gelişmişlik indeksi.
3. *Kamusal Alan & Hareketlilik:* Toplu taşıma durak yoğunlukları, turnike geçişleri ve GIS yaya aksı verileri.
4. *Hedef/Etiket (Ground Truth):* Belediye Temizlik İşleri kantar fişleri, 1. Sınıf Atık Getirme Merkezleri ve Akıllı Depozito Otomatı (RVM) tartım kayıtları.

- **Format & Boyut:** Yapılandırılmış tabüler veri (CSV / PostgreSQL) ve coğrafi mekânsal katman (GeoJSON) formatında **~10.000 kentsel nokta kaydı**.
- **Ön İşleme Adımları:** Eksik verilerin sektörel/mahalle medyanlarıyla tamamlanması (imputation), kategorik değişkenlerin Target/One-Hot Encoding ile kodlanması, sayısal özniteliklerin standartlaştırılması (StandardScaler) ve rota/yoğunluk metrikleri için mekânsal öznitelik mühendisliği.

5. Approach (Machine Learning or Deep Learning)

- **Seçilen Yaklaşım: Makine Öğrenmesi (Multi-Output LightGBM / XGBoost + HDBSCAN Mekânsal Kümeleme)**

- **Gerekçelendirme:**

- **Tabüler Veri Üstünlüğü:** Proje verisi heterojen demografik, ticari ve mekânsal tabüler değişkenlerden oluşmaktadır. Gradyan artırmalı karar ağaçları (GBDT), tabüler veri setlerinde derin öğrenmeye kıyasla daha yüksek doğruluk sağlar, daha az veriyle etkili genelleme yapar ve aşırı öğrenmeye (overfitting) karşı dirençlidir.
- **Açıklanabilirlik (Explainable AI - XAI):** Kamu bütçesi ve belediye kaynak tahsisi şeffaflık gerektirir. TreeSHAP entegrasyonu sayesinde her segment ve mahalle için atık tahminini oluşturan etkenler şeffafça raporlanabilir; bu durum kara kutu derin öğrenme modellerine göre kamusal karar vericiler için kritik bir güven avantajı sağlar.