

Project Idea Proposal: AI-Driven B2B Waste Generation Estimation & Lead Scoring for Recyclers

1. Project Idea

- **Problem Definition (Türkiye Uyarlaması):** Türkiye'deki lisanslı geri dönüşüm ve atık yönetim firmaları, KOBİ ölçeğindeki ticari işletmelerin (sanayi siteleri, zincir/yerel marketler, matbaalar, toptancılar, e-ticaret depoları) ne kadar ve hangi türde (karton/OCC, naylon/LDPE, plastik) geri dönüştürülebilir atık ürettiğini önceden bilememektedir. Bu veri eksikliği, saha satış ekiplerinin rastgele KOBİ ziyaretleri yapmasına, düşük tonajlı duraklara zaman harcanmasına, yüksek Müşteri Edinme Maliyetine (CAC) ve gereksiz araç yakıt sarfiyatına neden olmaktadır.
- **Proje Amacı:** KOBİ'lerin NACE sektör kodları, mekânsal büyüklükleri, müşteri yoğunlukları ve tedarik göstergelerini analiz ederek atık üretim potansiyellerini öngören; toplayıcı firmalara en karlı işletmeleri puanlayarak sunan bir **Makine Öğrenmesi Tabanlı B2B Lead Scoring ve Atık Tahminleme Sistemi** geliştirmektir.

2. Relevance to Sustainable Development Goals (SDGs)

- **SDG 12: Sorumlu Üretim ve Tüketim (Hedef 12.5):** KOBİ ölçeğinde kaynağında ayrıştırılan ticari ambalaj atıklarının toplanma verimliliğini artırarak düzenli depolama sahalarına (vahşi/katı atık depolama) giden geri dönüştürülebilir hammadde oranını doğrudan azaltır.
- **SDG 11: Sürdürülebilir Şehirler ve Topluluklar:** Atık toplayıcı filolarının rastgele gezmek yerine yalnızca yüksek hacimli ve doğrulanmış noktalara yönlendirilmesini sağlayarak kentsel lojistik kaynaklı karbon salımını ve trafik yoğunluğunu düşürür.
- **SDG 9: Sanayi, Yenilikçilik ve Altyapı:** Geleneksel, manuel ve verimsiz yürütülen yerel atık toplama sektörünü veri odaklı, dijital ve yapay zekâ tabanlı modern bir altyapıya kavuşturur.

3. Literature Examples

- **Örnek 1 — Kontokosta, C. E., & Hong, Y. (2018):** *"Machine Learning Models for Predicting Building-level Waste Generation."*
 - **Özet:** Binaların fiziksel özellikleri, mekânsal veriler ve işletme türlerini girdi olarak kullanarak Gradient Boosting ve Random Forest algoritmalarıyla bina düzeyinde atık miktarını tahmin etmiştir. Çalışma, kural tabanlı sabit çarpanlar yerine makine öğrenmesinin tahmin hatasını büyük ölçüde düşürdüğünü kanıtlamıştır.
- **Örnek 2 — Abbasi, M., & El Hanandeh, A. (2016):** *"Forecasting municipal and commercial solid waste generation using machine learning."*
 - **Özet:** Destek Vektör Makineleri (SVM) ve Yapay Sinir Ağları (ANN) kullanarak ticari ve kentsel katı atık üretim trendlerini modellemiştir. Sektörel sınıflandırma ve dönemsel ticari hareketliliğin atık çıktısı üzerindeki doğrudan

etkisini doğrulamıştır.

4. Describe Your Data

- **Veri Kaynakları:**
 - **İşletme Künyesi:** NACE faaliyet kodları, işletme kategorisi ve unvan bilgileri (Ticaret Sicil / Açık Firma Veritabanları).
 - **Mekânsal & Hareketlilik Verileri:** İşletme alan büyüklüğü ($\text{\$m}^2$), tahmini yaya/müşteri trafiği, popüler saatler ve yorum sıklığı (Google Places API / OpenStreetMap).
 - **Saha Doğrulama (Etiket) Verisi:** Belirli pilot sanayi siteleri ve perakende KOBİ'lerinden toplanan gerçek haftalık atık tartım kayıtları (kg/hafta - karton/plastik).
- **Veri Formatı ve Boyutu:** Tabüleri formatta (CSV / PostgreSQL) ve coğrafi koordinat verileri (GeoJSON). Pilot uygulama için hedeflenen veri boyutu: **3.000 – 5.000 KOBİ kaydı**.
- **Ön İşleme Adımları:**
 - Eksik verilerin sektör medyanlarıyla doldurulması (imputation).
 - Kategorik değişkenlerin (NACE kodları, ilçe/bölge) One-Hot / Target Encoding ile kodlanması.
 - Sayısal özniteliklerin (alan, yorum sayısı) standartlaştırılması (StandardScaler).
 - Toplama rotasına uzaklık ve yoğunluk metrikleri için öznitelik mühendisliği (Feature Engineering).

5. Approach (Machine Learning vs. Deep Learning)

- **Seçilen Yaklaşım: Makine Öğrenmesi (XGBoost, LightGBM ve Random Forest)**
- **Gerekçelendirme:**
 - **Tabüleri Veri Üstünlüğü:** Projede kullanılacak veri kümesi ağırlıklı olarak yapılandırılmış tabüleri ve coğrafi verilerden oluşmaktadır. Karar ağacı tabanlı algoritmalar (GBDT), tabüleri veri setlerinde derin öğrenme modellerine göre daha yüksek başarımlar sergiler ve aşırı öğrenmeye (overfitting) karşı daha dirençlidir.
 - **Açıklanabilirlik (Explainable AI - XAI):** Satış ve pazarlama ekiplerinin bir KOBİ'ye neden yüksek puan verildiğini anlaması gerekir. XGBoost ve SHAP analizleri ile öznitelik önem düzeyleri (Feature Importance) şeffaf şekilde raporlanabilir; bu durum kara kutu (black-box) derin öğrenme modellerine göre ticari süreçler için çok daha uygundur.